

### AI Detect Cancer in GI system, Gastrointestinal system

1. ระบุหัวข้อ IS/Project ที่จะทำ (AI-Enabled System) พร้อมกับเหตุผลว่าทำไม่ถึงต้องใช้ AI/ML เช่น IS/Project: AI Detect Cancer in GI system, Gastrointestinal system

เหตุผลที่ต้องใช้ AI: Model ที่ฝึกฝนมาอย่างดีสามารถตรวจจับรอยโรคในภาพวิดีโอได้ด้วยความแม่นยำสูง  
เหตุผลที่ต้องใช้ ML: Deep Learning สามารถเรียนรู้คุณลักษณะที่เหมาะสมที่สุดในการจำแนกและตรวจจับ  
รอยโรคได้ด้วยตัวเองจากข้อมูลภาพขนาดใหญ่ (Endoscopic Images/Videos) โดยตรง ทำให้สามารถค้นพบ  
รูปแบบที่ซับซ้อน และ ML สามารถได้รับการปรับปรุงและฝึกฝนซ้ำ (Retraining) ด้วยข้อมูลจากการนี้ศึกษาใหม่ ๆ

### 2. ออกแบบ Components ของระบบ (ไม่ต้อง Implement จริง)

2.1 ระบุ System Objectives ที่ Measurable, Achievable และ Communicable (Slide Week 2) รวมถึง System Goals, Leading Indicators, User Outcomes

#### System Objectives (Measurable, Achievable, Communicable)

- Measurable (วัดผลได้) Model ต้องเพิ่มอัตราการตรวจพบตั้งเนื้อที่จากลายเป็นมะเร็ง
- Achievable (ทำได้จริง) Model ต้องรักษาความแม่นยำในการระบุรอยโรคให้สูง
- Communicable (สื่อสารได้) Model ต้องช่วยลดความแปรปรวนของผลการตรวจระหว่างแพทย์

#### System Goals

- การตรวจพบ (Detection - CADe) ความไวในการตรวจจับรอยโรคต่อเฟรมวิดีโອอกของ Model ต้องสูงกว่า 90%
- การวินิจฉัย (Diagnosis - CADx) ต้องทำนายชนิดของติ่งเนื้อ (Neoplastic vs. Non-neoplastic) ได้ด้วยความแม่นยำ  $\geq 90\%$

#### Leading Indicators

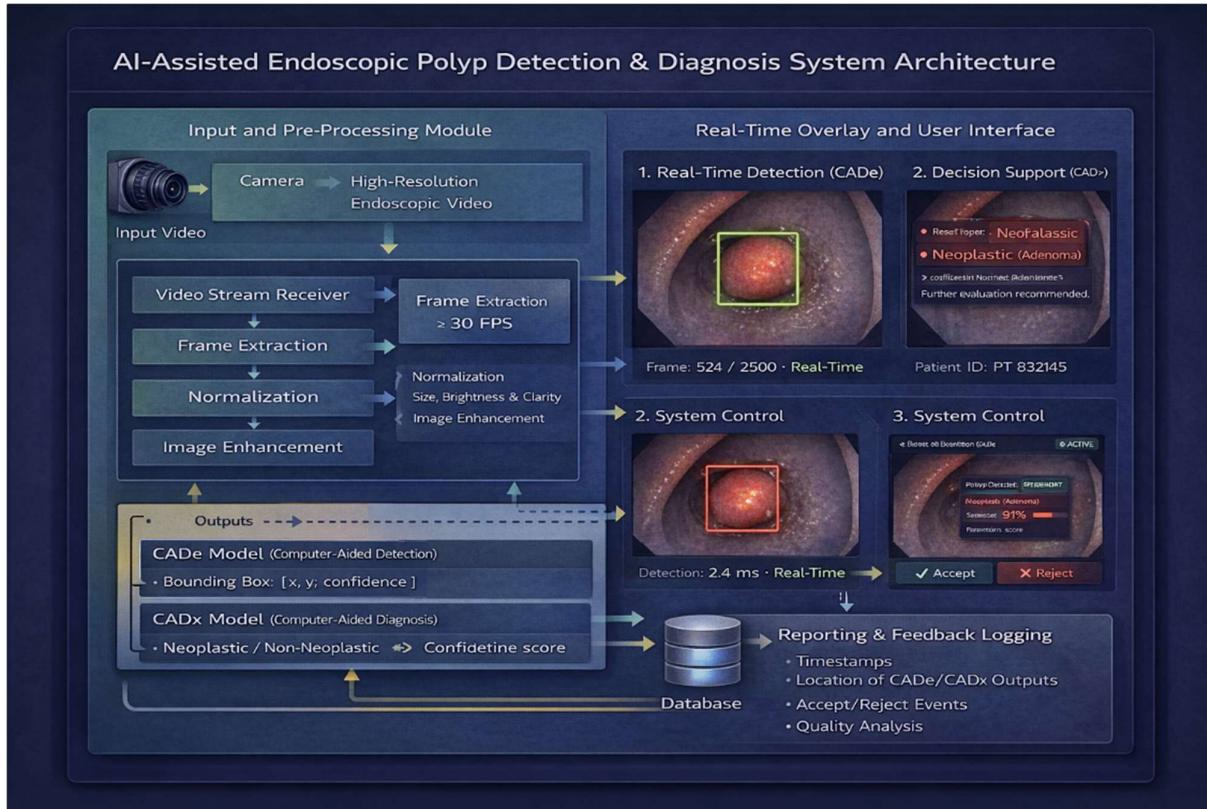
- อัตราการแจ้งเตือนผิดพลาด (False Positive Rate) วัดจำนวนครั้งที่ Model แจ้งเตือนในบริเวณที่ไม่ใช่รอยโรค ต่อเวลาที่ใช้ในการส่องกล้อง (ชั่วโมง FP/min) อัตราที่สูงเกินไปทำให้แพทย์เกิดความรำคาญและไม่เชื่อมั่นในระบบ
- ความหน่วงของระบบ (Latency) เวลาตอบสนองของ Model ในการแสดงผลบนหน้าจอ ความหน่วงสูงจะทำให้การตรวจมีอาการหน่วงและเกิดความผิดพลาดได้ง่าย

#### User Outcomes

- สำหรับแพทย์ ความมั่นใจในการวินิจฉัยเพิ่มขึ้น แพทย์มีความมั่นใจมากขึ้นในการวินิจฉัยรอยโรคขนาดเล็กหรือรอยโรคที่มีลักษณะแบบราก
- สำหรับผู้ป่วย ลดอัตราการเกิดมะเร็งลำไส้ใหญ่หลังการส่องกล้องเป็นผลลัพธ์ระยะยาวที่สำคัญที่สุด โดย ADR ที่สูงขึ้นจะนำไปสู่การลดอุบัติการณ์และลดอัตราการเสียชีวิตจากมะเร็ง
- ความแม่นยำที่สูงขึ้น ได้รับการตรวจที่มีคุณภาพส่วนมาก

## 2.2 ออกแบบ AI Components

### Data Flow



วิดีโอ → Frame Extraction ( $\geq 30$  FPS) → Normalization → CADe Model (Detection) → CADx

Model (Diagnosis) → Real-Time Overlay (แสดงผลบนหน้าจอแพทย์) → Logging (บันทึกข้อมูล)

ระบบมีส่วนประกอบหลักสามารถแบ่งออกได้เป็น 3 ส่วนหลัก คือ

- ส่วนประมวลผลวิดีโอ (Input/Pre-Processing)
- ส่วน Core Model (Model/Engine)
- ส่วนแสดงผล (Output/Interface)

### AI System Architecture Components

#### Input and Pre-Processing Module

ส่วนนี้มีหน้าที่รับวิดีโอ และเตรียมให้อยู่ในรูปแบบที่โมเดล Deep Learning สามารถประมวลผลได้รวดเร็วที่สุด

- Video Stream Receiver รับสัญญาณวิดีโอก่อนความละเอียดสูง (HD หรือ 4K)
- Frame Extraction แปลง Video Stream เป็นชุดของภาพนิ่ง (Frames)
- Normalization and Resizing ปรับขนาดภาพให้เป็นขนาดที่เหมาะสมกับ Model และปรับความสว่าง/ความคมชัด
- Image Enhancement การประมวลผลภาพเพื่อเพิ่มความชัดเจนของรอยโรคขนาดเล็กหรือรอยโรคที่มีลักษณะแอบแฝง

## Core AI Engine (Deep Learning Models)

ส่วนที่สำคัญที่สุด ประกอบด้วย Deep Learning Models ที่ทำงานควบคู่กันเพื่อการตรวจหาและการวินิจฉัย

- CADe Model (Computer-Aided Detection) ตรวจหาและระบุตำแหน่งของรอยโรคที่อาจเป็นติ่งเนื้อ (Polyp Detection and Localization) ใช้สถาปัตยกรรมประภาค One-Stage Object Detection ที่เน้นความเร็ว เช่น YOLO (You Only Look Once) โดยการ Bounding Box ครอบรอยโรคแต่ละจุด พร้อมค่า Confidence Score
- CADx Model (Computer-Aided Diagnosis) จำแนกประเภทของรอยโรคที่ CADe ตรวจพบ โดยใช้ Convolutional Neural Networks (CNNs) ที่มีความแม่นยำสูง เช่น ResNet การจำแนกประเภท Neoplastic (มีโอกาสเป็นมะเร็ง เช่น Adenoma) หรือ Non-Neoplastic (ไม่เป็นมะเร็ง เช่น Hyperplastic Polyp)

## Output and User Interface Module

- Real-Time Overlay แสดงผล Bounding Box หรือวงกลมสีบนภาพวิดีโอ ณ ตำแหน่งที่ CADe ตรวจพบ รอยโรค โดยวงกลมสีเขียว (Neoplastic) หรือสีน้ำเงิน (Non-neoplastic) พร้อม Confidence Level
- Logging and Reporting บันทึกข้อมูลการตรวจจับทั้งหมด (เวลา, ตำแหน่ง, ผล CADe/CADx) โดยอัตโนมัติ เพื่อใช้ในการสร้างรายงานและวิเคราะห์คุณภาพหลังการตรวจ โดยจะบันทึกข้อมูลลงในฐานข้อมูล (Database) ของระบบ

### 2.2.1 ระบุว่าจะใช้ Model เพื่อแก้ปัญหาใดในระบบ

- ภาระของชั้มรอยโรค CADe (Computer-Aided Detection) เพื่อเตือนแพทย์แบบ Real-Time
- ความผันผวนในการวินิจฉัย ความแม่นยำในการตรวจพบและจำแนกชนิดของรอยโรคแตกต่างกันไปตามประสบการณ์ของแพทย์แต่ละท่าน CADx (Computer-Aided Diagnosis) ช่วยจำแนกชนิดของติ่งเนื้อเพื่อให้การวินิจฉัยเป็นมากขึ้น

### 2.2.2 กำหนด System Goals, Leading Indicators, User Outcomes และ Model Properties

#### System Goals

- เพิ่มอัตราการตรวจพบติ่งเนื้อที่อาจกลایเป็นมะเร็งของแพทย์ผู้ใช้งาน
- ลดอัตราการเกิดมะเร็งลำไส้ใหญ่หลังการส่องกล้องโดยการป้องกันการมองข้ามรอยโรค

#### Leading Indicators

- Model Performance
  - o Sensitivity อัตราที่ตรวจพบติ่งเนื้อจริงได้ถูกต้อง
  - o False Positive Rate จำนวนการแจ้งเตือนที่ไม่ใช่ติ่งเนื้อจริง (ต้องอยู่ในระดับต่ำเพื่อไม่ให้แพทย์เสียสมาธิ)
- Latency เวลาที่ใช้ในการประมวลผลวิดีโอ 1 เฟรม (Frame Processing Time)

- Alert Utilization Rate อัตราที่แพทย์ใช้ใจและตอบสนองต่อการแจ้งเตือนของ Model

### User Outcomes

- แพทย์ ตรวจพบติ่งเนื้อได้มากขึ้นโดยเฉพาะติ่งเนื้อที่เล็กและมองยาก มีเครื่องมือช่วยตรวจจับตลอดเวลา และ CADx ช่วยวินิจฉัยชนิดติ่งเนื้อได้เร็วขึ้น ลดเวลาที่ใช้ในการตัดสินใจ
- ผู้ป่วย ลดความเสี่ยงเป็นมะเร็งและการรักษาที่แม่นยำขึ้น

### Model Properties

- Real-Time Speed ความสามารถในการประมวลผลวิดีโอที่อัตราเพื่อมสูง
- Robustness การส่องกล้องมีปัจจัยรบกวนสูง ไม่เดลต้องไม่เกิด False Positives หากเกินไป
- Interpretability สามารถแสดงผลลัพธ์ในรูปแบบที่สื่อสารง่าย มี Bounding Box และ Confidence Score ให้แพทย์เข้าใจว่า AI ตรวจพบอะไรและมีความแม่นใจแค่ไหน เพื่อประกอบการตัดสินใจ

### 2.2.3 ภาค AI/ML Canvas

Core Components: ระบบ AI ช่วยส่องกล้อง (AI-assisted Endoscopy)

Designed for : AI Detect Cancer in GI system, Gastrointestinal system		Date : October 15, 2025
Designed by : Somyong Phanjarak		Version : 1.0
<b>Prediction</b>	<b>Judgment</b>	<b>Action</b>
1. ตำแหน่งของรอยโรคบนวิดีโอดีด (Bounding Box) 2. โอกาสที่รอยโรคจะเป็นติ่งเนื้อ (Confidence Score) 3. ชนิดของติ่งเนื้อ (Neoplastic/ Non-Neoplastic)	* คุณภาพสูง: การตรวจพบติ่งเนื้อร้ายจริง (True Positive) และการวินิจฉัยถูกต้องตามผล Histopathology* ค่าใช้จ่ายสูง: False Negative (ผลซึ่งบกพร่อง) สรุปในรูปแบบที่ง่าย (PCCRC) หลังการส่องกล้อง (PCCRC)	ช่วยแพทย์ตรวจหา และจำแนก ติ่งเนื้อ (Polyp) ในลำไส้ใหญ่ แบบ Real-Time เพื่อลดอัตราการมองข้ามรอยโรค (Missed Lesions)
<b>Training</b>	<b>Input</b>	<b>Outcome</b>
ชุดข้อมูลขนาดใหญ่ ของภาพ/วิดีโอส่องกล้อง ที่ถูก Annotated (ระบุ Bounding Box และ Label ผล Histopathology ที่ถูกต้อง)	วิดีโอดีด (Live Video Stream Frames) ความละเอียดสูงจากกล้องส่องกล้อง	1. ADR (Adenoma Detection Rate) ของแพทย์ผู้ใช้งานเพิ่มขึ้น 2. Sensitivity/Recall ของ AI Model ( $\geq 95\%$ ในการตรวจจับ) 3. Latency ต่ำ ( $\leq 50\text{ms}/\text{Frame}$ )
<b>Feedback</b>		1. Human-in-the-Loop: บันทึกว่าแพทย์ยอมรับ หรือปฏิเสธ การแจ้งเตือนของ AI (ให้เป็น Ground Truth ใหม่) 2. ADR Tracking: ใช้ข้อมูล ADR ในโลกจริง มาเป็นตัววัดผลลัพธ์ทางคลินิกเพื่อปรับปรุงโมเดล ในเวลารันนิ่งต่อไป

### The AI Canvas



### 2.2.4 วิเคราะห์ Risk ที่จะเกิดขึ้นเมื่อ AI Component เกิดข้อผิดพลาด

#### ความเสี่ยงหลักจากข้อผิดพลาดของ AI (AI Component Failure Risks)

- False Negative (ข้อผิดพลาดจาก CADe) โมเดล CADe มองข้ามติ่งเนื้อที่สำคัญที่ไม่สมบูรณ์ ติ่งเนื้อที่เป็นมะเร็งถูกทิ้งไว้ เกิด Post-Colonoscopy Colorectal Cancer (PCCRC) ในเวลาต่อมา ซึ่ง เป็นความผิดพลาดร้ายแรงที่สุดในเชิงคลินิก

- False Negative (ข้อผิดพลาดจาก CADe) โดยเดลแจ้งเตือนผิด เสียเวลาในการตรวจสอบบุตรที่ไม่จำเป็น และอาจทำให้แพทย์ไม่เชื่อถือระบบ
- Latency Failure ความเสี่ยงต่อขั้นตอนการทำงาน: การแจ้งเตือนไม่สัมพันธ์กับภาพจริงบนหน้าจอ
- Model Drift ประสิทธิภาพที่เคยสูง Sensitivity ลดลงเรื่อยๆ นำไปสู่ False Negative เพิ่มขึ้นโดยไม่มีการแก้ไข

#### 2.2.4.1 ระบุREQ, ENV, SPEC

##### REQ (Requirements: ข้อกำหนด)

- Real-Time CADe สามารถตรวจจับรอยโรคและแสดงผล Bounding Box ตามรอยโรคได้
- CADx Capability สามารถจำแนกประเภทของรอยโรคเบื้องต้น (เช่น Neoplastic vs. Non-Neoplastic) ด้วยความแม่นยำสูง
- Minimized False Alarms ลดอัตราการแจ้งเตือนผิด (False Positive) ให้อยู่ในระดับที่ยอมรับได้ เพื่อไม่ให้แพทย์เกิด Alert Fatigue
- High Availability ระบบต้องพร้อมใช้งานอยู่ตลอดเวลาและมีกลไกสำรองเมื่อ Model ขัดข้อง

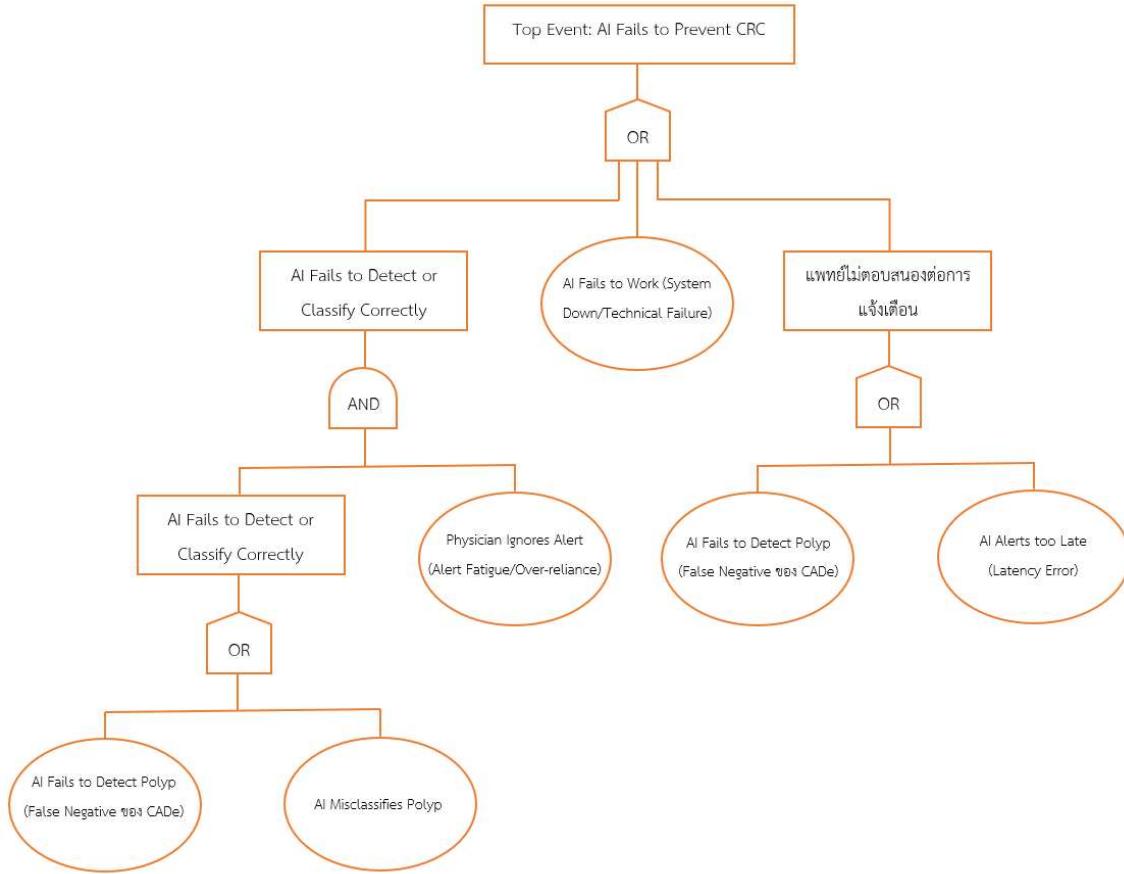
##### ENV (Environment: สภาพแวดล้อม)

- Operating Room/Endoscopy Suite ห้องปฏิบัติการส่องกล้องที่มีแสงสว่างเพียงพอ, มีผู้ปฏิบัติงาน (แพทย์, พยาบาล) ที่มีทักษะและ ADR ที่แตกต่างกัน
- AI Processing Unit Edge Device ที่มี GPU หรือ TPU ประสิทธิภาพสูงเพื่อรับการประมวลผล Real-Time
- Video Stream วิดีโอความละเอียดสูง (HD/Full HD) อัตราเฟรม 25-60 FPS ที่มีสัญญาณครบถ้วน (เช่น ฟองอากาศ, ของเหลว, การเคลื่อนไหวเร็ว)
- Visual Overlay การแสดงผลของ AI เป็น Bounding Box สีเขียว/แดง ข้อมูลบนภาพวิดีโอด้วย

##### SPEC (Specifications: คุณสมบัติเฉพาะทางเทคนิค)

- Detection Performance (CADe) Per-Polyp Sensitivity (ความไวในการตรวจจับตึงเนื้อต่อ 1 ชิ้น), Per-Frame Sensitivity (ความไวต่อ 1 เฟรมภาพ) และ False Positive Rate (FP) Per Exam (อัตราการเตือนผิดต่อการส่องกล้อง 1 ครั้ง)
- Classification Performance (CADx) Accuracy (ความแม่นยำในการจำแนกชนิดตึงเนื้อ)
- Real-Time Speed Latency เวลาในการประมวลผลต่อ 1 เฟรม และ First Detection Time (FDT) เวลาตั้งแต่ตึงเนื้อเข้าเพื่อมน AI ตรวจพบ
- Robustness Sensitivity เมื่อคุณภาพของภาพต่ำ

### 2.2.4.2 เจี๊ยบ Fault Tree Analysis พร้อมกับหา Minimum Cut



#### การหา Minimum Cut Sets

Minimum Cut Sets คือชุดเหตุการณ์พื้นฐานที่เล็กที่สุดที่เมื่อเกิดขึ้นพร้อมกันแล้วจะทำให้ Top Event เกิดขึ้น

$$\text{จากสมการ: } T = (A \cdot D + B \cdot D) + A + C + E$$

Minimum Cut Set (MCS)	Basic Events	Risk Description
MCS1	{A}	AI มองข้ามติ่งเนื้อจริง (CADe False Negative): เป็นช่องโหว่ วิกฤตที่สุด เพราะไม่ว่าจะเกิดอะไรขึ้น หาก AI ตรวจพลาดเอง ก็จะล้มเหลวทันที
MCS2	{B,D}	AI จำแนกติ่งเนื้อผิด (CADx False Diagnosis) AND แพทย์พึ่งพา AI มากเกินไป (Over-reliance): การรวมกันของ ข้อผิดพลาด AI กับการตัดสินใจผิดพลาดของมนุษย์
MCS3	{C}	การแจ้งเตือนของ AI ช้าเกินไป: (Latency Failure) รอยโรค หลุดเพริมไปก่อนที่ AI จะแสดงผล ทำให้การแจ้งเตือนไม่มีความหมาย
MCS4	{E}	ระบบล้มสมบูรณ์: (System Down) AI ไม่สามารถทำงานได้เลย ทำให้แพทย์กลับไปใช้การส่องกล้องแบบปกติ แต่หากแพทย์มี ADR ต่ออยู่แล้วก็จะเกิดความล้มเหลว

## สรุปความเสี่ยงที่วิกฤตที่สุด

Minimum Cut Sets ที่มีเพียงเหตุการณ์เดียว (MCS1 และ MCS3) คือความเสี่ยงที่ต้องจัดการเป็นอันดับแรก เพราะการเกิดเพียงเหตุการณ์เดียว ก็ทำให้ Top Event เกิดขึ้นได้ทันที

- AI มองข้ามติ่งเนื้อจริง (A) ต้องเพิ่ม Sensitivity ของโมเดลให้สูงสุด
- การแจ้งเตือนช้าเกินไป (C) ต้องมั่นใจว่าระบบมี Low Latency ( $\leq 50$  ms) และทำงานแบบ Real-Time อย่างแท้จริง

### 2.2.4.3 Strategies for mitigating the risks of failures

#### กลยุทธ์ในการบรรเทาความเสี่ยงของ AI Endoscopy Failure

- MCS1 (A) Model มองข้ามติ่งเนื้อจริง (CADe False Negative) เพิ่มความไวของโมเดล (Maximize Sensitivity)
  - o Data Augmentation ฝึกฝนด้วยข้อมูลที่มีความหลากหลายของติ่งเนื้อที่มองเห็นได้ยาก (แบบราก, ซ่อนอยู่หลังรอยพับ) และคุณภาพของภาพต่างๆ
  - o Ensemble Models ใช้โมเดลหลายตัวมาทำงานร่วมกันเพื่อเพิ่มโอกาสในการตรวจพบรอยโรคที่ยาก
- MCS2 (B, D) Model จำแนกผิด AND แพทย์พึงพาเกินไป
  - o แสดงค่า Confidence Score ของ Model ควบคู่ไปกับการแจ้งเตือน เพื่อให้แพทย์ตัดสินใจด้วยตนเอง
  - o พยายามทำให้ Model สามารถระบุว่าทำไม่ถึงหรือว่าสิ่งนั้นเป็นติ่งเนื้อ
- Model Drift ดำเนินการโดย Retraining Pipeline สร้างวงจรการฝึกฝนโมเดลใหม่เป็นประจำ โดยใช้ข้อมูลใหม่ๆ จากอุปกรณ์และผู้ป่วยที่หลากหลาย

## 2.3 ออกแบบ User Interactions (Intelligence Experiences)

### Real-Time Detection and Alert (CADe)

- Visual Cue (การเตือนด้วยภาพ) Model ต้องแสดง Bounding Box สีเขียวสดใส รอบรอยโรคที่ตรวจพบทันทีที่ Model มีความมั่นใจสูง (Confidence Score  $\geq 85\%$ )
- Persistence Bounding Box ต้องติดตามรอยโรคอย่างเสถียร (Stable Tracking) และหายไปทันทีเมื่อรอยโรคหลุดออกไปจากภาพหรือเมื่อแพทย์ตัดสินใจดำเนินการกับรอยโรคแล้ว

### Intelligent Confirmation and Characterization (CADx)

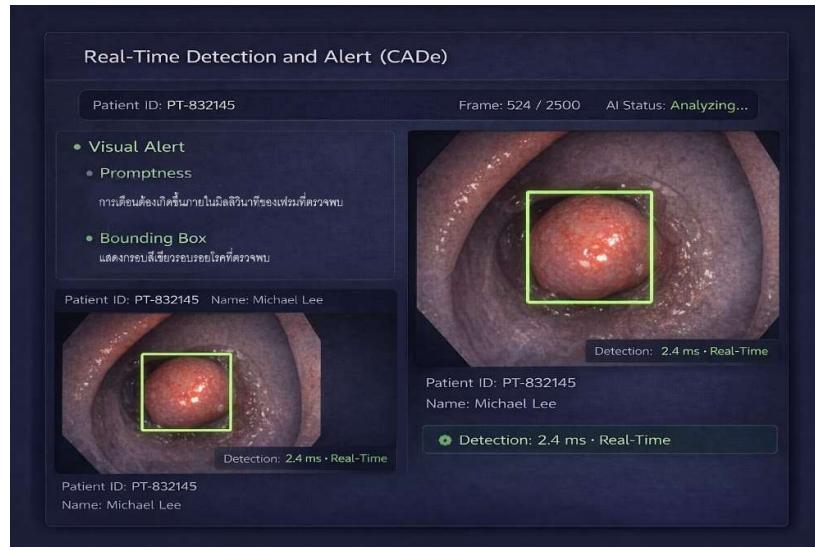
- Confidence Indicator แสดง Confidence Score (ค่าความมั่นใจ) ของ Model ว่ารอยโรคนี้เป็นติ่งเนื้อที่ต้องตัดออกหรือไม่ (Neoplastic หรือ Adenoma) เช่น "Neoplastic Probability: 92%"

## System Feedback and Control

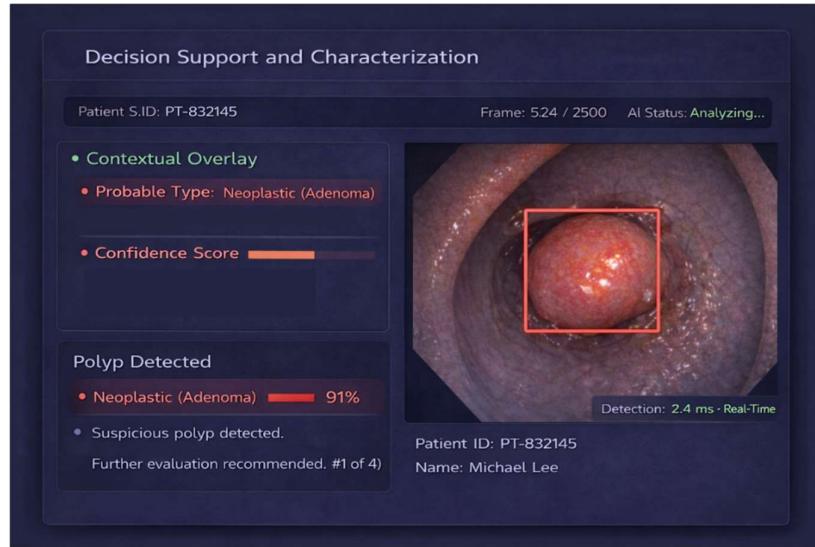
- Performance Summary ในส่วนของการรายงานผลหลังการตรวจระบบควรสรุปว่า Model ตรวจพบอย่างไรทั้งหมดกี่จุดและแพทย์ได้ดำเนินการกับรายโดยครบทั้งหมดหรือไม่ (Accepted/Ignored) เพื่อใช้ในการปรับปรุง ADR ในอนาคต

### 2.3.1 User Interactions Experience Design

#### Real-Time Detection and Alert (CADe)

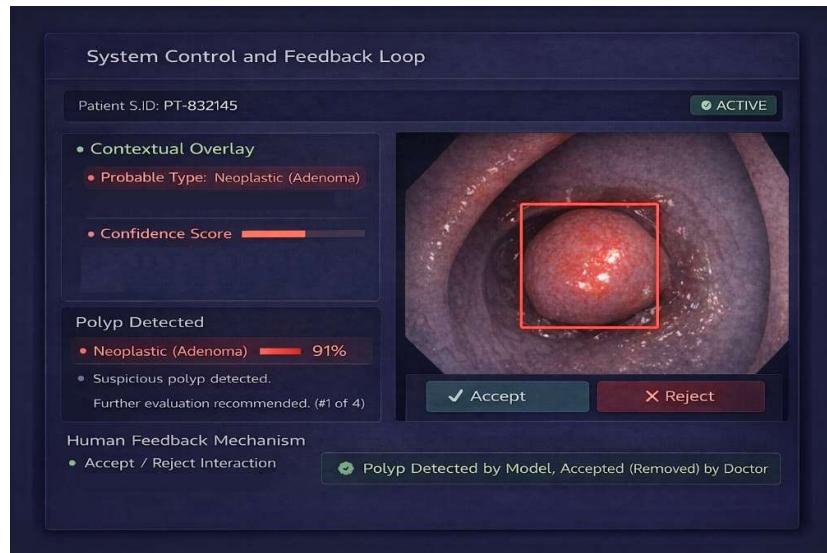


#### Decision Support and Characterization



- Contextual Overlay
  - o Probable Type "Neoplastic (Adenoma)" หรือ "Non-Neoplastic (Hyperplastic)"
  - o Confidence Score แสดงค่าความมั่นใจในการจำแนกชนิดของโรคที่ตรวจพบ
- Color Coding ใช้สีเพื่อสื่อความเสี่ยงทันที เช่น สีแดง/ส้ม-ความเสี่ยงสูง และ สีฟ้า/เหลือง-ความเสี่ยงต่ำ

## System Control and Feedback Loop



- Active Status Bar (ແນບສຕານະກາວທຳງານຂອງ Model)
  - o ACTIVE (ສື່ເຊີຍວ) ຮະບັບພ້ອມທຳງານແລະປະມວລຜົດ
  - o OFFLINE (ສື່ແດງ) ຮະບັບຄ່ມ/ປຶດກາວທຳງານ
- Human Feedback Mechanism Accept/Reject Interaction ເນື່ອແພທຍົດດຳເນີນກາຮັກບ່ຽຍໂຣຄື່ ຕຈາງພບ ລະບບຈະບັນທຶກ "Polyp Detected by Model, Accepted (Removed) by Doctor"

## 2.3.2 Where an AI model lives (ເຊັ່ນ Cloud, Edge, Embedded Devices) ໃຫ້ເຫັນພລມາໄດຍສັງເກີ

Deployment Location	ເຫັນພລ
<b>Edge Computing (Local Processing Unit)</b>	
Low Latency (Real-Time)	ກາຮັກປະມວລຜົດວິທີໂອກາຮັກສ່ອງກລໍ້ອໍານວຍໃຫ້ເຫັນພລມາໄດຍສັງເກີ ເພື່ອໃຫ້ຮະບັບສາມາດຮັດແຈ້ງເຕືອນຈອຍໂຣຄື່ໄດ້ແບບ Real-time ກາຮັກປະມວລຜົດບັນ Edge ຂ່າຍລົດຄວາມລ່າຍ້າທີ່ເກີດຈາກກາຮັກສ່ອງຂໍ້ມູນໄປຢັ້ງ Cloud
Reliability	ຮະບັບສາມາດຮັດໃຫ້ຍ່າງຕ່ອນເນື່ອງໂດຍໄມ້ຕ້ອງພັງພາກາຮັກເຊື່ອມຕ່ອອິນເທອຣົນັດ ທີ່ເສດືອຮອງໂຮງພຍາບາດ
Data Security & Privacy	ຂໍ້ມູນລົດວິທີໂອຂອງຜູ້ປ່າຍຖຸກປະມວລຜົດລາຍໃນໂຮງພຍາບາດຫຼື Endoscopy Suite ໂດຍໄມ້ຈໍາເປັນຕ້ອງສ່ອງອອກໄປກາຍນອກ ລດຄວາມເສີ່ງດ້ານຄວາມປຸດອຳກັຍແລະກາຮ ລະເມີດຂໍ້ມູນ

### 2.3.3 ระบุสิ่งที่ต้องพิจารณาเพิ่มเติมจาก Accuracy ของ Model ให้สอดคล้องกับ System Objective

เช่น ความเร็วในการ Predict, ขนาดของโมเดล เป็นต้น

- Sensitivity หรือ Recall เพื่อเพิ่ม ADR และป้องกัน False Negative
- False Positive Rate (FPR) ที่มีประสิทธิภาพและมาตรฐาน
- Latency มีความเร็วในการทำงานแบบ Real-Time และป้องกันความเสี่ยงในการตรวจจับโดยโรค
- Robustness ต้องทนทานต่อการเปลี่ยนแปลงของแสง, ฟองอากาศ, ของเหลว, หรือคุณภาพของภาพที่แตกต่างกันไปตามคุปกรณ์

### 2.3.4 How to compose models

Sequential Composition (การจัดเรียงตามลำดับ)

Endoscopy Pipeline โดยแยกกันทำงาน 2 model คือ

- Model ที่ 1 Detection (CADe) (ตรวจจับตำแหน่งติ่งเนื้อ) CADe Model รับภาพวิดีโอทั้งหมด
- Model ที่ 2 Classification/Characterization (CADx) (วินิจฉัยชนิดติ่งเนื้อ) ส่งภาพเฉพาะส่วนที่ถูกตรวจจับ (Cropped Bounding Box) ไปยัง CADx Model
  - o CADx สามารถใช้ Model ที่ขั้นตอนกว่าได้ เพราะทำงานบนภาพที่เล็กลง (Cropped Image)
  - o ลด False Positive ของ CADx เพราะไม่ต้องประมวลผลทั้งเฟรม

## 2.4 ออกแบบการเก็บข้อมูล Feedback จาก User และการ Monitor ประสิทธิภาพของ Model

Real-Time Feedback

Alert Acceptance/Rejection

- บันทึกว่าแพทย์ตัดสินใจทำอย่างไรเมื่อ Model แจ้งเตือน
  - o Accept แพทย์ตัด/นำขึ้นเนื้อออก
  - o Reject แพทย์เพิกเฉย/ระบุว่าเป็น False Positive

การ Monitor ประสิทธิภาพของ Model (Model Performance Monitoring)

- Model Drift (Prediction) ตรวจสอบว่า Confidence Score ของ Model ที่ Reject โดยแพทย์สูงขึ้น หรือไม่ ถ้าสูงขึ้นแสดงว่า AI เริ่มทำงานผิดพลาดขึ้นเรื่อยๆ

3. Implement โมเดลตามที่ได้ออกแบบไว้ในข้อ 2 โดยใช้ ML flow หรือ Tools อื่นที่นักศึกษานัด โมเดลใช้ในการตรวจจับและจำแนกติ่งเนื้อสามารถแบ่งออกเป็น 2 ส่วนหลัก ตามหน้าที่ของโมเดล

- CADe (Detection)
- CADx (Characterization)

### 3.1 ระบุข้อมูลนำเข้า

#### 3.1.1 อธิบายให้เห็นถึง Feature และลักษณะข้อมูล

##### Features และลักษณะข้อมูลสำหรับ CADe (Detection Model)

โมเดลตรวจจับ (CADe) มีเป้าหมายคือการระบุว่ามี "สิ่งผิดปกติ" อยู่ในภาพวิดีโอหรือไม่ และตำแหน่งอยู่ที่ใด ดังนั้น Feature ที่สำคัญที่สุดจะจึงเกี่ยวกับรูปร่างและขอบเขต

- Color และ Texture รูปแบบสีที่แตกต่างกัน (เช่น สีแดง/ชมพูจัด) และความชุกของพื้นผิว (Texture) ตั้งเนื้อส่วนใหญ่มักมีสีแดงจัดกว่าเยื่อบุลำไส้ปกติและมีพื้นผิวที่ผิดปกติไป
- Shape และ Contour รูปร่างของรอยโรค (เช่น โค้งมน, แบนราบ, มีก้าน) และขอบเขตที่ชัดเจนของรอยโรค (Sharpness) ใช้ในการแยกแยะติ่งเนื้อจากฟองอากาศ, กากอาหาร, หรือรอยพับของลำไส้

##### Features และลักษณะข้อมูลสำหรับ CADx (Classification Model)

โมเดลจำแนกชนิด (CADx) มีเป้าหมายคือการระบุว่าติ่งเนื้อที่ตรวจพบนั้นเป็นชนิดที่เป็นมะเร็ง (Neoplastic)

หรือไม่เป็นคันตราย (Non-Neoplastic) ดังนั้น Feature จึงเน้นไปที่รายละเอียดทางคลินิก (Clinical Details)

- Pit Pattern (รูปแบบหลุมบนเยื่อบุ) รูปแบบที่มองเห็นจาก Magnification Endoscopy เป็น Feature ทางคลินิกที่สำคัญที่สุดในการจำแนกชนิดของติ่งเนื้อ (ว่าเป็น Adenoma หรือ Hyperplastic)
- Vascular Network ความหนาแน่น, ความผิดปกติ, และรูปแบบของตาข่ายเลี้นเลือดที่ปรากฏบนพื้นผิวของรอยโรค
- Border และ Elevation ระดับความยกตัวของติ่งเนื้อจากเยื่อบุลำไส้ และความชัดเจนของขอบเขต โดยรอบ ติ่งเนื้อที่มีลักษณะแบนราบ (Flat หรือ Sessile) มักจะวินิจฉัยยาก แต่มีความเสี่ยงสูงกว่าติ่งเนื้อที่มีก้าน (Pedunculated) ในบางกรณี

#### 3.1.2 ในการนี้ที่ต้อง Training ข้อมูลที่มีขนาดใหญ่มาก มีวิธีแก้ไขอย่างไร

##### จัดการ Algorithm และ Model (Algorithmic และ Model Optimization)

- Transfer Learning ใช้โมเดลที่ถูก Training มาแล้วด้วยชุดข้อมูลทั่วไปขนาดใหญ่ (เช่น ImageNet) เป็นจุดเริ่มต้น แล้วปรับ Fine-tune ด้วยชุดข้อมูลทางการแพทย์ที่มีขนาดเล็กกว่า
- Efficient Model Architectures เลือกใช้โมเดลที่มีพารามิเตอร์น้อยและมี Computational Cost ต่ำ (เช่น MobileNet, EfficientNet หรือ YOLO เวอร์ชันล่าสุด) ซึ่งยังคงให้ประสิทธิภาพสูง

#### 3.1.3 ในการนี้ที่ข้อมูลมี Sensitive Features (Model fairness) มีวิธีการจัดการอย่างไร

- Bias Mitigation Techniques ปรับสมดุลข้อมูลด้วยเทคนิคต่าง ๆ เช่น การ Oversampling กลุ่มที่มีข้อมูลน้อย หรือใช้ Reweighting เพื่อลดอัตราพื้นของคุณลักษณะที่ละเอียดอ่อนในชุดข้อมูล
- Regularization Techniques การใช้ Fairness Constraints เพิ่มเงื่อนไขหรือค่าปรับ (Regularization Term) เข้าไปในฟังก์ชัน Loss

- Threshold Adjustment ปรับค่าเกลอนท์ (Threshold) ของ Confidence Score สำหรับแต่ละกลุ่มประชากรที่แตกต่างกัน เพื่อให้มาตรวัดมีความเที่ยงตรงและมีค่าเท่ากันในทุกกลุ่ม

### 3.2 ระบุวิธีการวัดคุณภาพของโมเดล (Model Quality)

การประเมินคุณภาพของโมเดลใช้ทั้งการวัดเชิงปริมาณ และเชิงคุณภาพ โดยระหว่างการฝึกโมเดลใช้ค่า Binary Cross-Entropy Loss เพื่อประเมินความคลาดเคลื่อนระหว่างผลท่านายและข้อมูลจริง และใช้ Pixel Accuracy เพื่อวัดสัดส่วนของพิกเซลที่โมเดลท่านายได้ถูกต้อง

หลังจากฝึกโมเดลเสร็จสิ้น จะประเมินประสิทธิภาพบนชุดทดสอบโดยใช้ตัวชี้วัดที่เหมาะสมกับงาน image segmentation ได้แก่ Dice Coefficient และ Intersection over Union (IoU) เพื่อวัดระดับความทับซ้อนระหว่าง mask ที่โมเดลท่านายกับ ground truth รวมถึงพิจารณาค่า Precision, Recall (Sensitivity) และ Specificity เพื่อสะท้อนความสามารถของโมเดลในการตรวจจับรอยโรคได้อย่างถูกต้องและครบถ้วน

นอกจากนี้ ยังมีการประเมินเชิงคุณภาพโดยการเปรียบเทียบภาพต้นฉบับ ผลการทำงานของโมเดล และ mask จริง เพื่อวิเคราะห์ลักษณะของข้อผิดพลาดและความเหมาะสมในการนำโมเดลไปใช้งานจริงทางการแพทย์

### 3.3 เขียน Code ใน การ Training Model (\*\*extra points) เขียน Unit Testing

```
1 history = model.fit(images, masks.reshape(-1, 128, 128, 1), epochs=50)

Epoch 1/50
Exception ignored in: <function _xla_gc_callback at 0x7d023debb4c0>
Traceback (most recent call last):
  File "/usr/local/lib/python3.12/dist-packages/jax/_src/lib/__init__.py", line 127, in _xla_gc_callback
    def _xla_gc_callback(*args):
KeyboardInterrupt:
32/32 ━━━━━━━━━━━━━━━━ 32s 531ms/step - accuracy: 0.8379 - loss: 0.5887
Epoch 2/50
32/32 ━━━━━━━━━━━━━━━━ 12s 389ms/step - accuracy: 0.8355 - loss: 0.4045
Epoch 3/50
32/32 ━━━━━━━━━━━━━━━━ 13s 395ms/step - accuracy: 0.8387 - loss: 0.3774
Epoch 4/50
32/32 ━━━━━━━━━━━━━━━━ 13s 399ms/step - accuracy: 0.8428 - loss: 0.3521
Epoch 5/50
```

### 3.4 เปรียบเทียบ Model ในข้อ 3.3 โดยใช้ MLflow Tracking UI (Week 3-4)

ในการทดลองนี้ ได้มีการฝึกโมเดลหลายรอบโดยปรับค่าพารามิเตอร์ที่แตกต่างกัน เช่น จำนวน epochs และ batch size และใช้ MLflow Tracking ในการบันทึกค่าพารามิเตอร์และผลการฝึกของแต่ละรอบการทดลอง

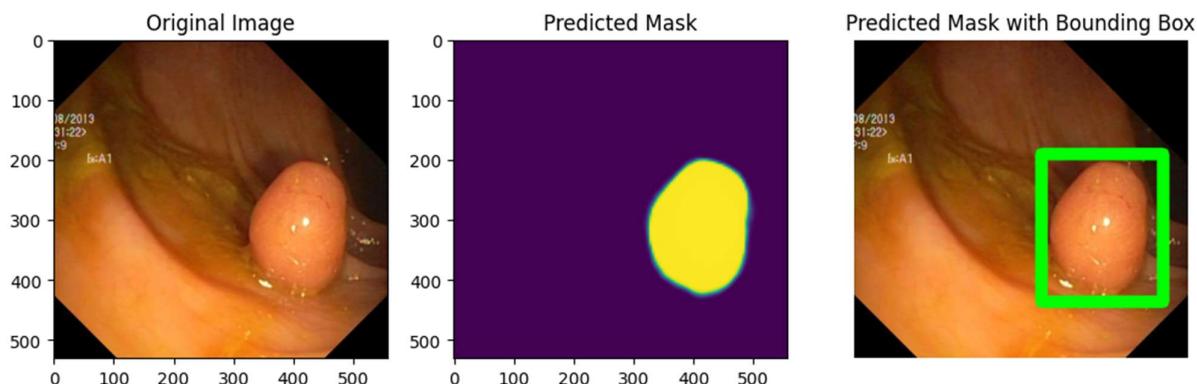
จาก MLflow Tracking UI สามารถเปรียบเทียบค่า loss และ accuracy ของแต่ละโมเดลได้อย่างเป็นระบบ ผลการทดลองพบว่าโมเดลที่มีจำนวน epochs มากกว่าสามารถเรียนรู้รูปแบบของข้อมูลได้ดีกว่า โดยมีค่า

validation loss ต่ำกว่าโมเดลอื่น อย่างไรก็ตาม การเพิ่มจำนวน epochs มากเกินไปอาจส่งผลให้เกิด overfitting จึงเลือกโมเดลที่มีประสิทธิภาพเหมาะสมที่สุดสำหรับการนำไปใช้งานต่อไป

### 3.5 Model explainability/Interpretability

เพื่อเพิ่มความสามารถในการอธิบายผลลัพธ์ของโมเดล (model explainability) ได้มีการแสดงผลการทำนายของโมเดลในรูปแบบเชิงภาพ โดยนำ mask ที่โมเดลทำนายได้ มาขึ้นทับบนภาพต้นฉบับ เพื่อให้เห็นบริเวณที่โมเดลให้ความสำคัญในการตัดสินใจว่าเป็นรอยโรค

จากผลการทำนายพบว่า โมเดลสามารถระบุบริเวณที่มีลักษณะสอดคล้องกับตำแหน่งของรอยโรคได้อย่างเหมาะสม โดยพื้นที่ที่ถูกทำนายว่าเป็นรอยโรค มีความสอดคล้องกับ ground truth ซึ่งช่วยให้ผู้ใช้งานสามารถเข้าใจเหตุผลเบื้องหลังการทำนายของโมเดล และเพิ่มความเชื่อมั่นในการนำโมเดลไปใช้งานในบริบททางการแพทย์



### 3.6 Prediction Reasoning

หลังจากที่โมเดลทำการทำนายภาพทางการแพทย์แล้ว ได้มีการวิเคราะห์เหตุผลประกอบการทำนาย (prediction reasoning) โดยพิจารณาจากตำแหน่ง ขนาด และลักษณะของบริเวณที่โมเดลทำนายว่าเป็นรอยโรค ซึ่งแสดงออกมากในรูปของ segmentation mask

จากการทำนายพบว่า โมเดลสามารถตรวจจับบริเวณต้องสงสัยได้ในตำแหน่งที่มีลักษณะผิดปกติจากเนื้อเยื่อรอบข้าง โดยบริเวณดังกล่าวมีขอบเขตชัดเจนและครอบคลุมพื้นที่สำคัญของรอยโรค การแสดงผลในรูปของ bounding box และ contour ช่วยให้สามารถอธิบายได้ว่าโมเดลใช้ข้อมูลเชิงพื้นที่ในการตัดสินใจ และผลลัพธ์ที่ได้มีความสมเหตุสมผลสอดคล้องกับลักษณะของโรคในทางคลินิก

### 3.7 Deploy Model โดยใช้ MLflow Models

หลังจากฝึกและประเมินประสิทธิภาพของโมเดลเรียบร้อยแล้ว ได้มีการนำโมเดลที่มีประสิทธิภาพดีที่สุดมาบันทึก และจัดการด้วย MLflow Models เพื่อเตรียมความพร้อมสำหรับการนำไปใช้งานจริง (deployment)

โมเดลถูกบันทึกในรูปแบบมาตรฐานของ MLflow ซึ่งช่วยให้สามารถโหลดและนำโมเดลไปใช้งานในสภาพแวดล้อมที่แตกต่างกันได้อย่างสะดวก เช่น การนำไปใช้งานผ่าน API โดยกระบวนการ deploy ประกอบด้วย การโหลดโมเดลจาก MLflow Model Registry จากนั้นทำการรับภาพใหม่ ทำการ preprocessing และส่งผลการคำนายน้ำหมึกในรูปแบบ segmentation mask

การใช้ MLflow Models ช่วยให้กระบวนการ deploy มีความเป็นระบบ สามารถติดตามเวอร์ชันของโมเดลได้ง่าย และสนับสนุนการนำโมเดลไปใช้งานจริงในระบบทางการแพทย์ได้อย่างมีประสิทธิภาพ

### 4. UI-Model Interface:

4.1 ออกแบบ interface ระหว่าง UI กับ Deployed Model โดยแสดงให้เห็นถึง Request payload ที่ส่งจาก UI และ Response Payload ที่ model ส่งกลับไปหา UI

ระบบ AI Detect Cancer in Gastrointestinal System ถูกออกแบบให้มี Interface ที่ชัดเจนระหว่าง UI/Capture Module และ Deployed AI Engine ซึ่งรวมโมเดล CADe และ CADx โดยใช้การสื่อสารในรูปแบบ Request–Response Payload เพื่อรองรับการประมวลผลแบบ Real-Time และการแสดงผลบนหน้าจอแพทย์อย่างมีประสิทธิภาพ

Request Payload (ส่งจาก UI/Capture Module ไปยัง AI Engine)

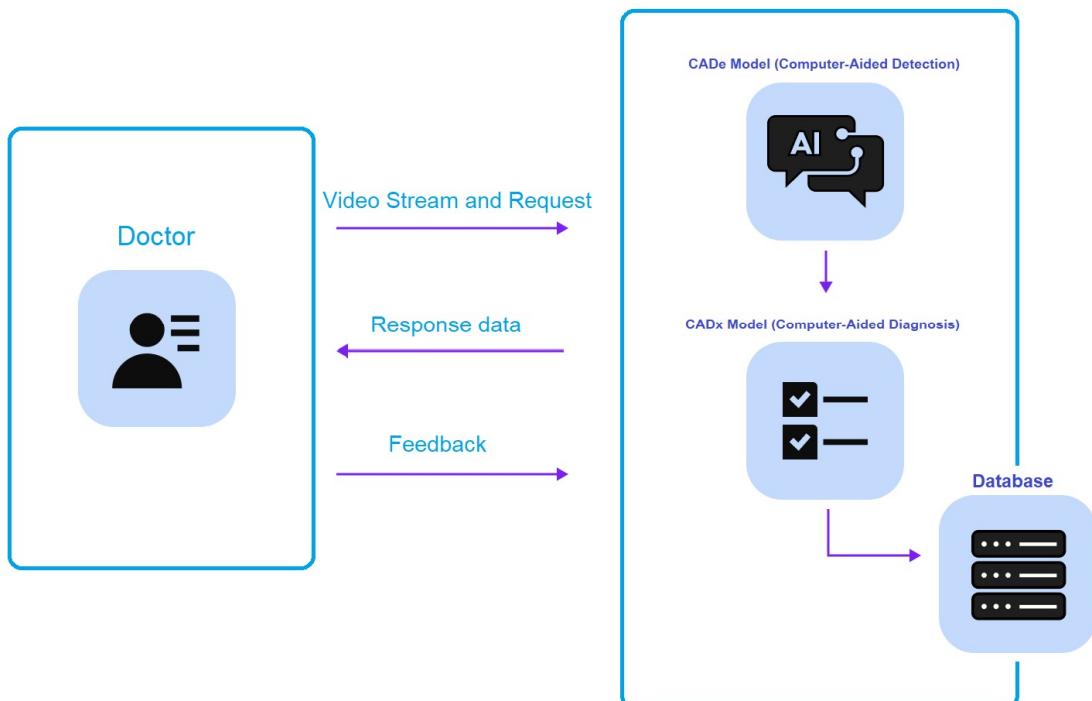
```
{  
    "frame_id": 16759,  
    "timestamp_ms": 1731652186742,  
    "device_id": "ENDO-SUITE-3",  
    "image_data_ref": "shmem://endo_buffer_a_1080p",  
    "image_width": 1920,  
    "image_height": 1080,  
    "current_mode": "WLI",  
    "pre_filter_status": "OK",  
    "physician_id": "DR_PICHER_05"  
}
```

### Response Payload (ส่งจาก AI Engine กลับไปยัง UI/Overlay Generator)

AI Engine ซึ่งรวมโมเดล CADe และ CADx ประมวลผลและส่งผลลัพธ์กลับไปยัง Overlay Generator เพื่อแสดงผลบนหน้าจอแพทย์

```
{  
    "frame_id": 16759,  
    "timestamp_response_ms": 1731652186784,  
    "latency_ms": 42,  
    "alert_status": "New_Polyp_Detected",  
    "detections": [  
        {  
            "id": 1001,  
            "box_2d": [150, 200, 50, 70],  
            "confidence_de": 0.985,  
            "prediction_dx": "Neoplastic",  
            "confidence_dx": 0.94,  
            "mode_used": "WLI"  
        },  
        {  
            "id": 1002,  
            "box_2d": [450, 600, 25, 40],  
            "confidence_de": 0.89,  
            "prediction_dx": "Non_Neoplastic",  
            "confidence_dx": 0.78,  
            "mode_used": "NBI"  
        }  
    ],  
    "system_status": "OK"  
}
```

AI Detect Cancer in GI system, Gastrointestinal system



### Payload-Level Interface for UI and Deployed AI Model

